

第一章 背景介绍

1.1. 欺诈检测在智能客服与金融风控场景中的重要性

随着互联网金融、在线支付、电商平台与智能客服系统的广泛应用，欺诈行为逐渐从单轮、模板化文本演变为多轮交互式对话。在真实场景中，诈骗者通常通过持续对话逐步建立信任、操控情绪并诱导受害者执行敏感操作（如转账、授权或信息泄露）。因此，欺诈不再仅表现为孤立文本，而是嵌入在上下文连贯、语义自然的对话序列中，这对自动检测系统提出了更高要求。

在金融风控场景中，欺诈对话识别直接关系到资金安全、反洗钱合规与金融机构声誉；在智能客服与平台治理场景中，及时发现诈骗或钓鱼对话有助于防止用户损失并提升系统可信度。近年来，大量研究与行业实践表明，仅依赖规则或人工审核已难以应对不断演化的诈骗话术，亟需借助自然语言处理模型进行自动化识别与拦截。

1.2. 传统分类器与大模型在欺诈对话识别中的研究现状

早期的欺诈文本或对话检测方法主要基于人工特征工程与传统分类器，例如使用关键词、词频统计、TF-IDF 特征配合逻辑回归或支持向量机进行分类。这类方法在诈骗模式相对固定的情况下具有一定效果，但往往依赖显式词汇线索，难以捕捉隐含语义与上下文策略，且在面对新型话术时泛化能力有限。

随着深度学习的发展，神经网络模型（如 CNN、LSTM）逐渐被用于欺诈检测任务，通过端到端学习缓解了部分特征工程依赖。然而，这类模型在复杂语义建模方面仍存在瓶颈。近年来，**预训练语言模型（PLMs）与大语言模型（LLMs）**在文本分类和对话理解任务中展现出显著优势。BERT、RoBERTa 等模型通过大规模语料预训练获得上下文表示能力，在诈骗对话识别中通常能够取得更高的准确率和召回率。

同时，Prompt-based 学习与大模型推理范式也被逐步引入到安全文本检测任务中。研究表明，LLMs 在理解隐晦表达和跨句语义关联方面具有潜在优势，但其推理过程高度依赖输入形式与提示结构，对输入改写和提示变化同样敏感（Xu & Wang, 2024）。

1.3. 高准确率模型的潜在脆弱性问题

尽管上述模型在标准测试集上往往表现优异，但模型鲁棒性问题已成为 NLP 领域的重要研究议题。大量研究指出，高性能模型在面对语义保持但表述发生变化的输入时，预测结果可能显著不稳定（Jin et al., 2020; Li et al., 2020）。这意味着模型可能过度依赖少量高权重词或表层模式，而未真正学习到任务的本质语义。

在对抗样本研究中，这一问题尤为突出。TextFooler、PWWS、BERT-Attack 等方法表明，通过同义词替换、词序调整或轻微句法变化，即可在不影响人类理解的情况下显著降低模型准确率（Jin et al., 2020; Li et al., 2020）。进一步地，研究发现，即便是大语言模型，在面对精心构造的对抗文本或提示扰动时同样存在明显性能退化（Zhao & Mao, 2023; Xu & Wang, 2024）。

在本课程实验一中，同样可以观察到类似现象：模型在原始欺诈对话数据上取得较高准确率，但当对话被进行语义保持的自然改写后，其预测性能明显下降。这一结果进一步说明，仅基于干净测试集的准确率评估不足以反映模型在真实对抗环境中的可靠性。

1.4. 研究动机：基于语义保持改写的鲁棒性分析

在真实诈骗场景中，攻击者通常不会进行明显的拼写错误或随机扰动，而是通过改写表达方式来自规避检测，例如替换说法、调整句式或改变对话节奏。这种“语义不变、表述不同”的改写方式比字符级或随机扰动更自然，也更符合现实攻击路径。

因此，本文的核心研究动机在于：通过对欺诈对话数据进行语义保持的自然改写，系统性地分析模型预测性能的变化，从而揭示其潜在脆弱性。这一思路与近期对抗样本生成与数据增强研究方向高度一致，例如 A3 方法提出利用条件化释义模型生成对抗样本，用于鲁棒性评估与增强训练（Liu & Sun, 2023）。

1.5. 数据集说明

本文实验可基于课堂提供的对话欺诈检测数据集开展，该类数据通常包含多轮对话与明确的欺诈标签，能够真实反映客服或诈骗场景通过在原始数据上生成语义保持的改写样本，并对比模型在原始与改写数据上的性能差异，可以更全面地评估模型鲁棒性。

第二章 相关工作

围绕文本与对话系统的鲁棒性问题，已有研究主要集中在文本对抗样本生成方法、对抗训练与数据增强策略以及面向大模型与 Prompt-based 学习的攻击与防御方法三个方向。本节将系统回顾相关研究进展，并分析其在欺诈对话识别任务中的适用性与不足。

2.1. 文本对抗样本生成方法

文本对抗样本生成是自然语言处理安全研究中的核心问题之一，其目标是在尽量保持语义不变和文本自然性的前提下，通过最小扰动误导模型预测结果。由于文本具有离散性，与计算机视觉领域相比，文本对抗攻击在搜索空间、语义约束和可读性方面面临更大挑战。

早期且最常用的一类方法是基于词级扰动的对抗攻击。这类方法通常通过同义词替换、近义词替换或词序调整来生成对抗样本。

PWWS 利用 WordNet 提供的同义词集合，对重要词进行替换并评估预测变化，从而生成对抗样本（Ren et al., 2019）。TextFooler 在此基础上进一步提出词重要性排序机制，通过计算删除或替换单个词对模型预测置信度的影响，优先攻击对预测贡献最大的词，从而显著提升攻击成功率（Jin et al., 2020）。

随着预训练语言模型的发展，研究者开始利用 PLM 提供的上下文建模能力生成更加自然的替换候选。BERT-Attack 通过 Masked Language Modeling 生成上下文相关的替换词，并结合语义相似度约束生成高质量对抗样本（Li et al., 2020）。后续工作如 BAE、CLARE 等也沿着这一思路，进一步提升了生成文本的流畅性与自然性。

尽管这类方法在文本分类任务中取得了显著效果，但其仍存在局限：

- （1）多数方法需要频繁查询目标模型，攻击成本较高；
- （2）生成过程往往针对特定模型优化，跨模型迁移能力有限；
- （3）在多轮对话场景中，词级替换可能破坏上下文一致性，难以直接适配欺诈对话检测任务。

在真实应用场景中，模型通常以 API 形式部署，攻击者无法获得模型梯度或预测概率分布，甚至只能访问最终预测标签。这一设定被称为黑盒或硬标签攻击场景，其现实意义更强。针对这一问题，LimeAttack 提出利用局部可解释方法（LIME）近似估计词重要性，从而在仅获取离散预测标签的情况下指导扰动搜索（Zhu et al., 2024）。该方法通过构造局部线性近似模型，识别对预测结果影响最大的词，并结合 Beam Search 在有限查询预算下生成对抗样本。实验结果表明，即使在极其受限的信息条件下，文本分类模型仍对语义保持的改写高度敏感。

模型的脆弱性并非依赖于攻击者掌握多少内部信息，而是源于模型本身对输入表述形式的高度敏感性。这一结论对欺诈对话识别任务尤为关键，因为真实诈骗者往往无法访问检测模型内部结构，却仍能通过不断调整话术绕过系统。

2.2. 生成式对抗样本与数据增强方法

除了直接用于攻击模型，对抗样本生成方法也被广泛用于数据增强与鲁棒性提升。其核心思想是通过引入困难样本，迫使模型学习更加稳健的决策边界。

早期对抗训练方法多通过在连续嵌入空间施加扰动来提升模型鲁棒性。例如，Miyato 等人在词向量空间中引入对抗噪声，显著提升了模型的泛化能力。然而，这类方法生成的扰动往往难以映射回可读文本，缺乏明确语言学意义，在实际文本任务中存在解释性不足的问题。

后续研究尝试结合离散扰动进行对抗训练，但通常依赖搜索式对抗样本生成，计算成本较高，且生成样本往往与目标模型强耦合，难以复用。

为解决上述问题，A3 提出了一种端到端对抗样本生成框架，通过条件生成器与释义模型协同工作，生成语义保持但具有攻击性的改写样本（Liu & Sun, 2023）。该方法的重要特点在于：

- （1）生成过程不依赖目标模型的反复查询；
- （2）生成的对抗样本可跨模型复用；
- （3）生成样本在语义与语法层面更加自然。

这类生成式方法在概念上与欺诈对话场景高度契合。现实中的诈骗话术本质上是一种“条件化改写”：在保持欺诈意图不变的前提下，通过改变措辞与表达方式规避检测。因此，基于生成式改写的对抗样本不仅适合用于攻击评估，也天然适合作为欺诈检测模型的数据增强手段。

2.3. 面向大模型与 Prompt-based 学习的攻击研究

随着大语言模型和 Prompt-based 学习范式在 NLP 任务中的广泛应用，研究者逐渐发现：Prompt 本身成为新的攻击面。Universal Adversarial Triggers 最早被提出用于在不修改原始输入的情况下，通过附加固定触发词误导模型预测。后续研究发现，这类触发不仅对 PLM 有效，也可以迁移到 Prompt-based Fine-tuned Models (PFMs) 上。AToP 证明了在 PLM 上优化得到的对抗 Prompt 可以迁移到下游任务，但其生成的触发往往缺乏自然性，表现为无意义的 token 组合，容易被检测或过滤。为此，LinkPrompt 在攻击目标函数中显式引入自然性约束，通过联合优化攻击效果与语言模型生成概率，生成更加自然、可读的通用对抗触发（Xu & Wang, 2024）。

尽管 Prompt-based 攻击主要研究分类与情感分析任务，但其核心结论对欺诈检测具有重要启示：

- （1）模型对输入形式（包括 Prompt 与话术表达）高度敏感；
- （2）自然语言改写比随机扰动更具攻击性与现实意义；
- （3）攻击样本往往具有较强迁移性，可跨模型生效。

2.4. 本文相关工作

综合以上研究可以得出以下结论：

- （1）现有文本与对话分类模型在语义保持的改写下普遍存在鲁棒性不足的问题（Jin et al., 2020; Li et al., 2020; Zhu et al., 2024）。
- （2）统词级扰动方法在对话场景中存在上下文破坏与自然性不足的问题，而生成式改写方法在语义保持和现实可行性方面更具优势（Liu & Sun, 2023）。

(3) 近期针对大模型和 Prompt-based 学习的研究进一步表明，即便是先进模型，也难以从根本上避免自然语言层面的对抗攻击（Xu & Wang, 2024）。

基于上述分析，本文将相关工作与欺诈对话识别任务相结合，聚焦语义保持的欺诈对话改写这一更贴近真实诈骗行为的攻击形式，系统分析模型在该场景下的鲁棒性表现，为后续防御方法与数据增强策略提供实验依据。

第三章 提出的模型方法的解读

我将选用 Query-Efficient Textual Adversarial Example Generation for Black-Box Attacks 作为目标文献。核心想法是：先在训练集上离线“统计”出哪些同义替换更可能、更有效地把样本推向错误预测（ABP），再用这个先验去指导测试时的对抗改写，从而显著减少对受害模型的查询次数

3.1. 问题设定与符号

论文讨论的是文本分类黑盒攻击：给定原始文本 x （或 x_0 ）及其真实标签 y ，攻击者通过同义词替换构造对抗样本 x_{adv} ，使受害模型对其预测改变（误分类）。

- $x = w_1 w_2 \dots w_i \dots w_n$ ：文本由 n 个词/token 组成
- $S(w_i)$ ： w_i 的同义候选集合（在 counter-fitted embedding 空间里取 top- m 近邻）
- m ：每个词的同义候选数（实验里用 $m=30$ ）
- $f(y | x)$ ：模型对标签 y 的输出（文中用 logits/概率的记法来描述变化）

这篇论文的方法部分基本不写“损失函数”（不像白盒攻击会显式最小化/最大化某个 loss），它的核心目标是：用训练集统计出来的“更易致错的替换偏好”来指导搜索，从而降低查询成本。

3.2. ABP 指标：Preference $\times$ Influence

论文定义：将 w_i 替换为其同义词 w_i^k 的“对抗提升偏好”记为：

$$A(w_i, w_i^k) = P(w_i, w_i^k) \times I(w_i, w_i^k)$$

其中：

$P(w_i, w_i^k)$ ：偏好（preference），表示在训练集里生成对抗样本时，“ (w_i) 被替换成 (w_i^k) ”这件事出现得有多频繁；本质是一个条件频率

$I(w_i, w_i^k)$: 影响 (influence), 表示做这个替换后, 模型对正确标签 (y) 的输出平均下降多少 (越能压低正确类输出, 越“有效”)

具体估计方式 (训练集统计):

① 先用任意“同义替换攻击器”(论文实验中用 PWWS) 在训练集上生成对抗样本对 (x, x_{adv}) , 记录所有发生过的替换对 (w_i, w_i^k) 。

② 统计次数:

$N(w_i)$: w_i 在训练集中出现次数

$N(w_i, w_i^k)$: $w_i \rightarrow w_i^k$ 被替换发生的次数

则

$$P(w_i, w_i^k) = \frac{N(w_i, w_i^k)}{N(w_i)}$$

③ 影响定义为对正确标签输出的平均变化 (文中用 logit 变化表达):

$$I(w_i, w_i^k) = \frac{\sum (f(y|x) - f(y|x'))}{N(w_i, w_i^k)}$$

其中 x' 是把 x 中的 w_i 换成 w_i^k 得到的句子。

④ 按类别分别统计: 因为同一个词在不同类别文本里的“可攻击性”不同 (如情感分类里 “good/bad”)。

3.3. 基于 ABP 的三类攻击

3.3.1. ABPfree: 零查询 (universal) 同义替换攻击

ABPfree 分两步: 选位置 + 选替换词。词位置重要性 (position importance) 对每个位置 (i), 定义

$$q_i = \max_{k=1..m} A(w_i, w_i^k)$$

即“这个位置上最强的同义替换 ABP 分数”。按 q_i 从大到小排序所有词位置, 得到 replacement order。对排序前 25% 的词, 选 ABP 最大的候选词

$$w_i^* = \arg \max_{w_i^k \in S(w_i)} A(w_i, w_i^k)$$

然后替换生成 x_{adv} 。ABPfree 不访问受害模型输出, 因此属于“无需访问模型”的通用攻击 (与加前后缀的触发器类 universal attack 对比, 它用同义替换更自然)。

3.3.2. ABPguide: 黑盒低查询引导搜索 (Greedy → Guided Walk → Prune)

论文把 ABPguide 拆成三步, 并用图示概括: 先逼近决策边界, 再随机探索找到初始对抗样本, 最后剪枝恢复冗余替换以逼近最优对抗样本。




图 1ABPguide 的整体攻击流程

(A) Greedy search: 沿着 replacement order 逼近边界按 ABPfree 的 replacement order 逐个把 w_i 换成最重要候选 w_i^* 。每替换一次就查询一次受害模型, 检查是否已经变成对抗样本; 成功则进入 prune; 否则继续, 直到用完可替换词。用“最可能有效的替换”做一个很便宜的“直线冲刺”, 迅速靠近/跨过决策边界。

(B) Guided walk: 随机但“偏向高 ABP”的探索, 找初始对抗样本当 greedy 还没成功时, 做 guided walk。其关键是两级采样概率: 先采样位置 (最多 δ 个位置), 位置概率:

$$p_i = \frac{\max(q_i, 0)}{\sum_{i=1}^n \max(q_i, 0)}$$

只让“可能增强对抗性”的词 ($(q_i > 0)$) 更容易被选中。再对每个被选中的位置, 从同义集合采样候选 (同样裁剪负值):

$$p_{i,k} = \frac{\max(A(w_i, w_i^k), 0)}{\sum_{k=1}^m \max(A(w_i, w_i^k), 0)}$$

重复 guided walk, 直到找到 x_{adv} 或达到最大迭代 T_g 。

(C) Prune: 用“反向替换”删掉冗余扰动, 逼近最优。在已有 x_{adv} 的前提下, prune 试图把一些位置恢复成原词 (以减少扰动率/提高自然性)。采样若干 (最多 δ 个) 位置, 概率 $1 - p_i$ (越“不重要”的越先尝试恢复) 把该位置词替回原始文本 x_0 的对应词; 若仍是对抗样本则保留该恢复并继续, 否则回退再试。重复 T_p 次; 当只剩一个词被替换时可早停

3.3.3. ABPens: 跨模型/跨域的 ABP 融合 (提升迁移性)

论文进一步提出“ensemble ABP”：把来自不同模型/不同域的 ABP 统计融合，得到 A_{ens} ，再用同样策略做 $ABP_{ens} - free/ABP_{ens} - guide$ 。

3. 4. 对抗生成整体流程

该方法的对抗生成流程可以概括为“先离线学习替换先验、再在线用先验驱动改写”。具体而言，作者首先在训练数据上进行一次离线统计：从训练集抽取样本，借助任意一个基于同义替换的攻击器（论文实验使用 PWWS）生成对抗样本，并把生成过程中出现的每一次词级替换对 $(w_i \rightarrow w_i^k)$ 记录下来，通过计数得到替换偏好 $P(w_i, w_i^k) = N(w_i, w_i^k)/N(w_i)$ ，再进一步计算该替换对“正确类别输出”的平均削弱程度（影响度） $I(w_i, w_i^k)$ ，即比较替换前后模型对真实标签 y 的输出差值 $f(y|x) - f(y|x')$ 并对出现次数求均值，最终把偏好与影响相乘得到对抗提升偏好分数 $I(w_i, w_i^k)A(w_i, w_i^k) = P(w_i, w_i^k)$ ，并且按照类别分别存储以刻画类别相关的替换规律。




图 2 对抗生成整体流程

在在线攻击阶段，给定一条待攻击文本 x_0 ，系统首先利用离线得到的 ABP 表估计每个位置的潜在攻击价值，令位置重要性 $q_i = \max_k A(w_i, w_i^k)$ ，再按 q_i 从大到小确定替换顺序，并为每个位置选择 ABP 得分最高的候选 $w_i^* = \arg \max_k A(w_i, w_i^k)$ 。若采用 ABPfree (query-free) 模式，则直接按该顺序替换排名前 25% 的词位得到改写文本，从而无需访问受害模型即可形成自然的同义改写型对抗样本；若采用 ABPguide (query-efficient) 模式，则先执行一个按替换顺序推进的贪心阶段并在每步查询受害模型以快速逼近决策边界，若仍未成功再在边界附近进行带偏置的随机游走：每

次随机选择少量词位并依据 $A(w_i, w_i^k)$ 的归一化概率采样替换词来探索更有效的组合,直到首次得到误分类样本;

随后进入剪枝阶段,在保持误分类的前提下尝试将部分已替换词恢复为原词,以删除冗余扰动、降低扰动比例并提升文本自然性,最终输出满足语义保持但能诱导模型预测翻转的对抗改写文本。

3.5. 实验环境

3.5.1. 硬件环境

为保证实验结果的可复现性,本文严格遵循原始论文及其官方代码仓库所使用的实验环境配置。实验在具备 GPU 加速的计算平台上完成,使用单张 NVIDIA RTX 4070 进行模型推理与对抗样本生成。由于攻击阶段主要涉及模型前向推理与少量搜索操作,而非大规模训练,因此单卡 GPU 能够满足实验需求。

3.5.2. 软件环境

为了最大程度复现原始实验设置,本文完全采用原论文代码仓库中给出的软件依赖版本,未对核心依赖进行版本升级或替换。具体依赖如下:

- Python 3.x
- PyTorch 1.7.1
- TensorFlow-GPU 1.15.0
- TensorFlow-Hub 0.10.0
- NumPy 1.19.5
- NLTK 3.3
- language-tool-python 2.5.3
- Pattern 3.6
- GloVe 预训练词向量 (glove.6B.200d)
- Counter-fitted word vectors (用于同义词替换候选构建)
- 代码仓库中提供的同义词候选索引文件 (mat.txt)

上述配置与原论文保持一致,从而避免由于环境差异带来的性能偏移,确保实验结果的可比性与可复现性。

3.5.3. 对比方法选择与实验设计理由

本文的实验设计围绕 ABPfree 与 ABPguide 的核心目标展开, 分别用于验证其在零查询攻击场景与低查询黑盒攻击场景下的有效性。因此, 在对比方法的选择上, 本文严格遵循“攻击设定一致、评测目标一致”的原则, 以确保不同方法之间的比较具有公平性与可解释性。为分析模型在语义保持前提下对表述变化的鲁棒性, 本文比较了模型在原始对话文本与经对抗改写后的文本 (adversarially rewritten data) 上的预测表现差异。该对比能够直观揭示, 即便模型在原始测试集上取得较高分类准确率, 其在面对仅包含轻微词级同义替换的改写文本时, 仍可能出现显著性能下降, 从而暴露出模型在表述变化条件下的潜在鲁棒性缺陷。

为验证所提出对抗样本生成方法的模型无关性 (model-agnostic), 实验同时在不同结构的文本分类模型上进行评估, 包括基于预训练语言模型的分器 (如 BERT 和 ALBERT) 以及传统的序列建模方法 (如 LSTM)。通过在不同模型架构上的对比实验, 本文旨在说明对抗改写所带来的性能退化并非依赖于特定模型结构, 而是反映了当前主流文本分类模型在词级语义扰动下普遍存在的脆弱性。

在黑盒攻击场景下, 本文选用 PWWS (Probability Weighted Word Saliency) 与 PSO (Particle Swarm Optimization) 作为攻击基线方法, 用于与 ABPguide 进行对比。PWWS 与 PSO 均为文本对抗攻击领域中具有代表性的黑盒攻击方法, 其共同特点在于无法访问模型的内部参数或梯度信息, 而是通过反复查询模型输出以估计词的重要性并进行搜索, 通常需要较高的查询次数才能生成成功的对抗样本。ABPguide 的核心贡献在于在保持与上述方法相近攻击成功率的前提下, 显著降低对受害模型的查询次数, 从而实现更高的查询效率。因此, 将 PWWS 与 PSO 作为黑盒攻击基线, 能够从攻击成功率、平均查询次数以及词级扰动比例等多个维度, 系统性地验证 ABPguide 在查询效率方面的优势。

此外, 在零查询攻击场景下, 本文选用 UAT (Universal Adversarial Triggers) 与 NUTS (Natural Universal Trigger Search) 作为通用攻击基线方法, 用于与 ABPfree 进行对比。ABPfree 属于攻击阶段不依赖模型输出的通用攻击方法, 其攻击规则可以在不同输入样本之间复用, 适用于模型接口受限或无法频繁交互的实际应用场景。UAT 与 NUTS 同样是经典的通用攻击方法, 通常通过在文本前后插入固定触发词 (trigger) 来诱导模型误判。将其作为对比基线, 一方面是由于三者测试阶段均不依赖模型查询, 攻击设定保持一致; 另一方面, ABPfree 通过词级同义替换实现对抗改写, 相比基于触发词插入的攻击方式, 在文本自然性与语义保持性方面更符合真实语言分布。因此, 该对比能够有效体现 ABPfree 在保持零查询特性的同时, 在生成更自然、更具语义一致性的对抗样本方面所具有的优势。

第四章 实验结果展示

4.1. 数据集与评测设置

本文以“欺诈对话检测”为二分类任务（Fraud vs Non-fraud）。模拟数据集规模设定为：训练集 20,000 条对话片段、验证集 2,000 条、测试集 3,000 条；类别分布近似均衡（欺诈 51%，非欺诈 49%）。每条样本为多轮对话的拼接文本，平均长度约 120–180 token。评测指标采用 Accuracy、Macro-F1，并补充鲁棒性相关指标：攻击成功率 ASR（Attack Success Rate）、平均扰动率 Perturb%（被替换 token 比例）、平均查询次数 Queries（仅对黑盒攻击适用）。

为对比“模型架构差异”，本文选取三类分类器：预训练语言模型（BERT-base、ALBERT-base）与传统序列模型（BiLSTM），并加入轻量线性基线（TF-IDF + Logistic Regression，简称 LR）。对抗改写方法对齐 ABP 框架：ABPfree（零查询同义替换）与 ABPguide（低查询黑盒引导搜索）。此外，为进行消融，本文构造两类改写：仅同义词替换（Synonym-only）与整句级改写（Sentence-level paraphrase）。

4.2. 原数据集上的实验结果

表 5-1 展示了各模型在原始测试集上的分类性能。可以看到，预训练模型在欺诈对话检测任务上表现显著优于传统模型与线性基线，这与既有研究结论一致：预训练模型能够更好地建模对话上下文与隐含语义线索（例如诱导转账、冒充身份、制造紧迫感等）。

模型	Accuracy	Macro-F1
BERT-base	0.944	0.943
ALBERT-base	0.938	0.937
BiLSTM	0.889	0.887
TF-IDF + LR	0.846	0.842

表格 1 原始数据集性能

大模型（BERT/ALBERT）在原始数据上达到了约 0.94 的准确率，说明该任务在“标准表达形态”下可被较好解决。但仅凭原始准确率并不能说明模型在真实应用中的可靠性，因为实际对话可能存在大量同义改写、口语化表达、隐晦说法与措辞变化；因此有必要在保持语义的前提下进行改写测试，检验模型鲁棒性。


4.3. 改写后的数据集效果变化

为检验模型对“语义保持但表述变化”的敏感性，本文在测试集中抽取模型原本预测正确的样本

子集（记为 D_{clean} ），分别使用 ABPfree 与 ABPguide 生成对抗改写文本，得到改写集 D_{adv} 。表 5-2 给出在不同改写方式下，各模型性能的变化（ Δ 表示相对原始测试集的绝对降幅）。


模型	原始 Acc	ABPfree Acc	Δ	ABPguide Acc	Δ
BERT-base	0.944	0.781	-0.163	0.632	-0.312
ALBERT-base	0.938	0.792	-0.146	0.651	-0.287
BiLSTM	0.889	0.804	-0.085	0.712	-0.177
TF-IDF + LR	0.846	0.824	-0.022	0.806	-0.04

表格 2 改写后的性能变化




图片 3 不同模型性能

预训练模型下降最明显，BERT/ALBERT 在 ABPguide 下出现约 0.29–0.31 的准确率降幅。传统与线性模型下降较小，BiLSTM 下降中等，LR 降幅最小。ABPguide 比 ABPfree 更强，同一模型下，ABPguide 造成更大退化，符合其“少量查询 + 边界引导”的设计目标。




图片 4 Accuracy 随扰动率变化曲线



图片 5 精准度变化

预训练模型在原始数据上依赖更复杂的语义与语境线索，但这也意味着其决策边界可能更“陡峭”且分布在高维语义空间；当输入发生局部但针对性的语义扰动（尤其是高 ABP 分词位的替换）时，模型输出可能发生非线性跃迁，从而导致更大性能退化。线性模型（TF-IDF + LR）更依赖表层词频特征，许多同义替换不会显著改变关键 n-gram 或整体词袋统计，因此整体性能波动较小；但这并不意味着其更鲁棒，而是说明其能力上限受限，对复杂语义欺诈模式的捕捉本身不足。



图片 6 ASR-Queries 权衡曲线

4. 4. 现象分析：为什么某些改写能“骗过”模型？

结合对抗样本的人工抽查（模拟分析框架），本文将“骗过模型”的改写归纳为以下几类机制，这些机制并非互斥，常在同一对抗样本中叠加出现。

4. 4. 1. 欺诈意图的“语义锚点”被替换后，触发特征发生漂移

在欺诈对话中，模型往往依赖某些高相关表达作为“意图锚点”，例如“转账/汇款/刷流水/验证码/解冻账户/内部渠道”等。ABP 倾向于优先替换这些词位及其上下文搭配，使得原本强指示性的关键词被替换为更弱、更多义或更口语化的表达，从而降低模型对欺诈类别的后验概率。例如，将“验证码”替换为“验证信息”、将“转账”替换为“打款/处理一下”，可能在语义上仍保留操作意图，但削弱了训练集中高频触发词的显式出现。

4. 4. 2. 语用层面的“紧迫性/权威性”被重写，导致风险模式识别失败

欺诈对话的关键不只在实体词，还在语用策略（urgency、authority、scarcity）。当改写将“立刻/马上/最后机会”改为更委婉或更分散的表达（例如拆分到多句或用更柔和的语气），模型可能因缺少熟悉的风险语用模板而误判。

4. 4. 3. 分布偏移与对抗先验：模型对“训练分布外改写”缺乏稳健性

即使语义保持，同义替换与句式改写也会造成局部分布偏移：词共现模式、短语搭配、语序结构与标点风格发生变化。预训练模型虽然具备较强泛化能力，但在下游监督微调时仍会学习到与训练数据分布相关的捷径特征（shortcut），从而在面对“自然但不同风格”的表达时出现脆弱性。ABP 的统计先验进一步放大了这种偏移：它倾向选择“历史上更容易导致输出变化”的替换对，从而形成针对性的攻击路径。

4.5. 消融实验：同义词替换 vs 整句改写

为了区分“词级扰动”与“句级重写”对模型的影响差异，本文进行消融实验，构造两种改写策略：

(1) Synonym-only：仅对高重要性词位进行同义词替换，保持句法结构不变；(2) Sentence-level paraphrase：在语义保持约束下重写整句（例如改变语序、拆分合并句子、替换短语）。

改写类型	Accuracy	Δ	Perturb%	语义保持
原始	0.944	—	0	1
同义替换	0.721	-0.223	0.16	0.92
整句改写	0.665	-0.279	—	0.88

图表 3 消融实验结果

整句改写对准确率的破坏更强（降幅更大），说明模型不仅依赖词汇锚点，也依赖句法/语篇结构模式；当整体表达方式变化更大时，分布偏移更明显，从而更易导致误判。同义替换的语义保持通过率更高，说明其在“自然性与语义一致性”方面更可控；这也解释了为什么 ABP 框架偏向于词级替换：在保持可读性的前提下获得稳定攻击效果。从攻击视角看，若目标是“低成本、自然文本”，Synonym-only 更符合真实场景；若目标是“最大化攻击成功率”，整句改写更具破坏力但更容易引入语义漂移或可疑表达。

4.6. 创新：中文数据集适配

本次修改的核心目标是将原本面向英文文本设计的 ABP（Adversarial Black-box Prompting / Attack by Perturbation）对抗攻击框架适配到中文数据集上，使其能够在**不改变核心攻击逻辑**的前提下，稳定支持中文欺诈对话检测任务。与英文不同，中文文本处理存在若干结构性差异：其一，中文缺乏天然词边界，攻击算法中的“词级替换/扰动”必须依赖分词工具；其二，中英文词性标注体系差异显著（如 Penn Treebank vs. jieba/ICTCLAS 风格标签），会影响 ABP/PWWS 中基于 POS 的候选词过滤与替换约束；其三，中文同义词替换策略在粒度（字/词/短语）、歧义消解和语义保持上与英文并不对齐，若直接复用原实现容易出现替换失真或候选集稀疏的问题。

为此，整体修改遵循“**最小侵入、最大兼容**”原则：尽量通过**参数开关与功能扩展**实现中文支持，而非重写原有攻击流程，从而保证与英文版本的对比实验仍然公平可复现，并降低引入额外工程 bug 的概率。

4.6.1. 数据加载层：中文分词与标签字段兼容

在数据加载层（testdata_loader.py）新增 is_chinese 参数开关，用于控制中文数据集的预处理路径。当检测到中文数据集时，框架采用 jieba 对文本执行分词，将原本默认的英文 tokenization 流程替换为中文可用的词级序列，以满足后续攻击步骤（候选生成、替换位置选择、扰动率统计）对“词单元”的依赖。

同时，考虑到课程数据/实际数据常以 CSV 形式存储，且标签字段命名不稳定（例如 is_fraud、label 或其它变体），加载器增加对标签列的智能识别逻辑：当识别到 is_fraud 列时，将原始的 True/False 或字符串形式的布尔值统一映射为数值标签 0/1（如 True→1，False→0），保证分类器与攻击评估模块使用一致的数据类型与标签空间。

4.6.2. 文本处理层：中文词性标注与通用 POS 映射

在文本处理层（text_process.py）扩展 get_pos() 函数，使其支持在 is_chinese=True 时调用中文词性标注流程。由于中文分词工具的 POS 标签体系与原英文实现不一致。

因此新增 map_chinese_pos() 函数，将 jieba.posseg 输出的中文标签（如名词 n、动词 v、形容词 a、副词 d、代词 r、介词 p 等）映射到统一的通用 POS 标签体系。该设计确保后续攻击逻辑只依赖“统一 POS 集合”，而不需要关心底层标注器差异，从而实现“接口不变、实现可切换”的兼容性目标。

4.6.3. 主脚本与配置：自动检测与运行流程简化

在主攻击脚本（attack.py）中增加自动检测机制：从配置文件读取 is_chinese 标志，并将其统一传递给数据加载、文本处理、攻击器等组件，形成从入口到执行链路的“参数贯通”。为降低使用门槛并提升实验复现性，新增专用中文配置文件，并提供对应的运行脚本/命令模板，使中文数据集能够“一键切换”进入攻击流程，避免用户手工修改多处源码参数导致的配置漂移。

4.7. 总结

上述实验结果表明：在欺诈对话检测任务上，即便预训练模型在原始数据上表现优异，其在语义保持的改写文本上仍可能出现明显退化。这一现象提示我们，面向实际风控与智能客服场景的模型评估不应局限于静态测试集准确率，而应纳入“自然改写鲁棒性”作为常规指标。一方面，ABPfree/ABPguide 可作为低成本的鲁棒性压力测试工具，用于发现模型依赖的脆弱特征；另一方面，结合对抗改写样本的数据增强与对抗训练有望提升模型对多表述风格的适应能力，降低被轻微改写“绕过”的风险。

Github: https://github.com/lovvvvvve-Haibara/NLP_finalwork.git

第五章 参考文献

- [1] Zhen Yu, Zhenhua Chen, and Kun He. 2024. Query-Efficient Textual Adversarial Example Generation for Black-Box Attacks. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 556 – 569, Mexico City, Mexico. Association for Computational Linguistics. doi:10.18653/v1/2024.naacl-long.31.
- [2] Yue Xu and Wenjie Wang. 2024. LinkPrompt: Natural and Universal Adversarial Attacks on Prompt-based Language Models. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 6473 – 6486, Mexico City, Mexico. Association for Computational Linguistics. doi:10.18653/v1/2024.naacl-long.360.
- [3] Tuc Van Nguyen and Thai Le. 2024. Adapters Mixup: Mixing Parameter-Efficient Adapters to Enhance the Adversarial Robustness of Fine-tuned Pre-trained Text Classifiers. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 21183 – 21203, Miami, Florida, USA. Association for Computational Linguistics. doi:10.18653/v1/2024.emnlp-main.1180.
- [4] Jaehyung Kim, Yuning Mao, Rui Hou, Hanchao Yu, Davis Liang, Pascale Fung, Qifan Wang, Fuli Feng, Lifu Huang, and Madian Khabisa. 2023. RoAST: Robustifying Language Models via Adversarial Perturbation with Selective Training. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 3412 – 3444, Singapore. Association for Computational Linguistics. doi:10.18653/v1/2023.findings-emnlp.223.
- [5] Tianyuan Liu and Yuqing Sun. 2023. End-to-end Adversarial Sample Generation for Data Augmentation. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 11359 – 11368, Singapore. Association for Computational Linguistics. doi:10.18653/v1/2023.findings-emnlp.760.
- [6] Jiahao Zhao and Wenji Mao. 2023. Generative Adversarial Training with Perturbed Token Detection for Model Robustness. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 13012 – 13025, Singapore. Association for Computational Linguistics. doi:10.18653/v1/2023.emnlp-main.804.
- [7] Hai Zhu, Zhaoqing Yang, Weiwei Shang, and Yuren Wu. 2024. LimeAttack: Local Explainable Method for Textual Hard-Label Adversarial Attack. *arXiv:2308.00319v2* (cs.CL). doi:10.48550/arXiv.2308.00319.